

编程作业-第七章

作业说明

本次作业只包含一道题目，要求大家先下载好语料库，随后按要求编写python代码并命名为**t1.py**。随后撰写pdf格式的作业报告，命名为**report.pdf**，内容包括简单讲解代码实现逻辑，并回答题目中的问题。

将代码和报告放在同一目录下，打包成zip文件，命名为{你的名字}_{你的学号}.zip，**并提交至网络学堂**。注意提交至网络学堂的压缩包中**一定不要包含语料库!!!**

例如 张三_2025010001.zip

```
|—— t1.py
|—— report.pdf
```

请注意：

- 编程作业为个人作业，请独立完成。如果提交的代码参考了资料或个人，请在源代码文件中通过注释来标注来源，否则视为抄袭。
- 为方便评判，请同学们按照规定格式提交作业。

题目：汉字词频统计(100分)

词频统计是自然语言处理中的重要一环。我们为大家准备了新浪新闻的汉语语料库与一二级汉字表。[点击这里下载](#)。语料库共包含9个txt文件，一二级汉字表是一个独立的txt文件。

你需要：

- 下载好语料库与一二级汉字表。在代码里读入文件时，请通过gbk编码打开文件。
- 利用正则表达式对语料库进行清洗，要求只保留在一二级汉字表中的汉字。**如果你认为单纯的保留所有汉字不利于下述词频统计任务，也可以结合语料库内容选择你认为合理的清洗方式。**请使用 `os.listdir()` 或 `pathlib.Path.iterdir()` 等方法自动读取语料库目录中所有 .txt 文件，不得硬编码文件名。且清洗过程必须使用 `re` 模块实现，禁止使用 jieba 等第三方分词工具。在报告中展示你使用的清洗方式与正则表达式。(40分)
- 统计出现频率最高的前十个汉字。在报告中展示这十个字。(20分)
- 统计出现频率最高的前十个二元词，其中二元词指的是在**原语料库中相邻出现的两个汉字的组合**。在报告中展示这十个二元词。(20分)
- 结合语料库内容与我们平时使用汉字的习惯，从你刚刚统计好的出现频率最高的十个字与十个词中，各挑选两个进行简要分析。在报告中简单解释它们出现频率高的合理性。(20分)

例：假设原语料库中有这样一句话：“你好，我是李华”，则“你好”“我是”“是李”“李华”都被视作二元词，但“好我”不算。

本题目比较开放，没有固定的准确答案。由于清洗数据的方式与正则表达式选用的不同，每个人统计出来的结果可能也会有所区别。大家在报告中言之成理即可。